



UNIVERSIDADE DA CORUÑA

Facultad de Informática

Grado en Inteligencia Artificial

Modelos avanzados de aprendizaje automático I

Human activity recognition

Rodrigo García Romero
Alberto Blanco Lamela
Ana Valls Bendicho

19 de diciembre de 2025

Índice

1. Introducción	2
1.1. Descripción de los datos	2
2. Preparación y preprocesado	3
2.1. Unificación de los datos	5
2.2. Tratamiento de valores ausentes	6
2.3. Separación de datos	6
3. Estructura y ejecución	6
4. Resultados modelos básicos y selección de atributos	8
5. Resultados modelos ensemble	14
6. Resultados finales por bloque	15
6.1. Modelos básicos	15
6.2. Modelos ensemble	16
6.3. Modelos compuestos	16
7. Gráficas por reducción	17
8. Visualización y análisis de reducciones	17
9. Significación de variables	21
9.1. Importancia según Random Forest	22
9.2. Importancia según XGBoost	23
9.3. Conclusión de la significación por variables	23

1. Introducción

En este trabajo haremos un estudio sobre la aplicación de diversas combinaciones de tipos de modelos de aprendizaje automático, filtrados de características y reducciones por proyección para abordar un problema de clasificación sobre un dataset de actividad humana obtenido mediante el análisis de posición, velocidad y aceleración de móviles posicionados en cinturones de 30 sujetos.

El desarrollo de un sistema que pueda diferenciar si una persona está moviéndose o estática puede ayudar a combatir el creciente sedentarismo que se está propagando en la sociedad actual. Este puede implementarse en aplicaciones de salud que monitoreen a sus usuarios para darles avisos para que hagan actividad física después de cierta cantidad de tiempo de estar sentados o tumbados. Siendo capaz de medir el grado en el que se realiza esta actividad.

1.1. Descripción de los datos

El dataset está compuesto por un total de 10299 muestras repartidas entre los individuos con la siguiente distribución:




Figura 1: Muestras por individuo

Podemos observar que no hay una distribución equitativa de muestras entre los participantes pero las diferencias son admisibles, por lo que no haremos ni undersampling ni oversampling. Dentro de cada sujeto, podemos ver una proporción relativamente equilibrada de cada clase, por lo que no tenemos que preocuparnos de tener conjuntos con clases desbalanceadas.

Las clases en general tienen esta distribución:




Figura 2: Muestras por clase

Se puede observar que WALKING_DOWNSTAIRS y WALKING_UPSTAIRS están subrepresentadas en comparación con el resto pero, teniendo en cuenta que hay 6 clases distintas, no hay tanta diferencia con las otras como para requerir manipular la distribución de las clases.

2. Preparación y preprocesado

Estas muestras están a su vez compuestas de 561 variables relacionadas con la posición, velocidad y aceleración de los móviles de los sujetos. Entre estas, encontramos datos faltantes en casi todas:




Figura 3: Valores faltantes agrupados por individuo

Pero muy claramente podemos ver unas columnas con muchos más datos faltantes que otras, siendo las 11 que más tienen:

- tBodyGyroMag-mad(): 1033
- tBodyGyroMag-iqr(): 1033
- fBodyAcc-mad()-Y: 1032
- fBodyAccJerk-mean()-X: 1032
- tBodyAccJerk-energy()-X: 1030
- tBodyAccJerk-entropy()-Y: 1030
- tBodyAccMag-max(): 1030
- tGravityAccMag-std(): 1030
- tGravityAccMag-entropy(): 1030
- fBodyAcc-std()-X: 1030

- fBodyBodyGyroMag-iqr(): 1030

Estas cantidades no son preocupantes, representando aproximadamente un 10 % de las muestras totales por columna.

La mayoría de las variables se encuentran entre -1 y 1 y con desviación típica alrededor de 0.3, aunque hay algunos que tienen un rango más acotado pero siempre entre esos dos valores. Esto nos permite aplicar la normalización MinMax sin problema, ya que no nos vamos a encontrar outliers que desbalancen la transformación.

2.1. Unificación de los datos

Originalmente los datos se encontraban almacenados en varias carpetas distintas creadas por dos investigadores distintos con dos metodologías distintas: el investigador A los separaba en carpetas de acuerdo al día en el que se tomaba la muestra y dentro de eso los separaba por sujeto, mientras que el investigador B tenía una única carpeta con un csv por individuo.

```
DatosPractica
|-- Investigador A
|   |-- day 1
|   |   |-- Sujeto_01.csv
|   |   |-- Sujeto_05.csv
|   |   |-- Sujeto_06.csv
|   |   '-- Sujeto_11.csv
|   |-- day 2
|   |   |-- Sujeto_03.csv
|   |   |-- Sujeto_09.csv
|   |   |-- Sujeto_23.csv
|   |   '-- Sujeto_25.csv
|   |-- day 3
|   |   |-- Sujeto_15.csv
|   |   |-- Sujeto_17.csv
|   |   '-- Sujeto_21.csv
|   |-- day 4
|   |   |-- Sujeto_13.csv
|   |   '-- Sujeto_19.csv
|   '-- day 5
|       |-- Sujeto_27.csv
|       '-- Sujeto_29.csv
'-- Investigador B
    |-- Sujeto_02.csv
```

```
|-- Sujeto_04.csv  
|-- Sujeto_06.csv  
|-- Sujeto_08.csv  
|-- Sujeto_10.csv  
|-- Sujeto_12.csv  
|-- Sujeto_14.csv  
|-- Sujeto_16.csv  
|-- Sujeto_18.csv  
|-- Sujeto_20.csv  
|-- Sujeto_22.csv  
|-- Sujeto_24.csv  
|-- Sujeto_26.csv  
|-- Sujeto_28.csv  
'-- Sujeto_30.csv
```

Para simplificar el trabajo sobre los datos, decidimos unificar todos los archivos en un único archivo csv.

2.2. Tratamiento de valores ausentes

Como los datos faltantes parecen ser MCAR y no son excesivos, decidimos imputar los datos con la media por sujeto en esa columna. Esto se hizo para evitar hacer data leakage entre los datos de entrenamiento, validación y test; ya que estos conjuntos serán separados individuo a individuo.

2.3. Separación de datos

Como ya se mencionó en el apartado anterior, decidimos separar los datos en entrenamiento, validación y test individuo a individuo; es decir, todas las instancias de un individuo aparecen únicamente en uno de los conjuntos.

Para ello, usamos un holdout del 10 % para los datos de test y un 5-fold crossValidation para separar validación y entrenamiento, ambas usando la semilla 104.

3. Estructura y ejecución

El código que se ha de ejecutar se encuentra en un fichero de Jupyter-Notebook llamado P2_Notebook.ipynb. Dentro de este archivo el código se separa en diferentes secciones:

1. Importación de dependencias

2. Tratamiento de datos
3. Entrenamiento de modelos simples
4. Entrenamiento de modelos de ensemble
5. Visualización de los datos
6. Significación de variables

El código auxiliar, es decir, funciones y wrappers que creamos para el desarrollo de la práctica se ubican en archivos .jl que son importados junto al resto de librerías externas.

Para la correcta ejecución del trabajo, se ha de ejecutar el Notebook previamente mencionado en su totalidad y en orden.

Para el desarrollo de la práctica se ha hecho uso de las siguientes librerías:

- Entrenamiento y modelos
 - MLJ
 - MLJFlux
 - MLJScikitLearnInterface
 - NearestNeighborModels
 - LIBSVM
 - MLJModelInterface
 - MLJBase
 - LightGBM
 - DecisionTree
 - XGBoost
 - DecisionTree
 - EvoTrees
 - CatBoost*
- Tratamiento de datos
 - CategoricalArrays
 - DataFrames
 - CSV
 - Tables

- Métodos estadísticos
 - StatsBase
 - Statistics
 - HypothesisTests
 - InformationMeasures
- Reducción de dimensionalidad
 - MultivariateStats
 - TSne
 - ManifoldLearning
- Visualización
 - Plots
 - PlotlyJS
- Misceláneo
 - Random

4. Resultados modelos básicos y selección de atributos

Se probaron diferentes combinaciones para los modelos básicos, teniendo en cuenta el análisis de filtrados y reducciones de dimensionalidad antes del entrenamiento de estos. Con el objetivo de identificar para cada modelo los mejores parámetros para la tarea de clasificación.

Los experimentos se realizaron con las combinaciones de los siguientes elementos:

- **Clasificadores base e hiperparámetros:**
 - **KNN:** Se han probado valores de $k \in \{1, 10, 20\}$.
 - **SVM:** Se han probado parámetros $C \in \{0, 1, 0, 5, 1, 0\}$.
 - **MLP:** Se han probado tres arquitecturas de capas ocultas: $[50]$, $[100]$ y $[100, 50]$.
- **Métodos de filtrado:**

- Anova
- Pearson
- Spearman
- Kendall Tau
- RFE
- Mutual Information
- Sin filtrado

■ Técnicas de reducción:

- PCA
- ICA
- LDA
- Sin reducción

Para cada una de estas combinaciones, se ha empleado una validación cruzada de 5 *folds* de tipo *subject-wise*.

Cuadro 1: MLP_100

Filtrado	Sin filtrado		PCA_10		LDA		ICA_10	
	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD
None	90,55 $\pm$ 3,03	89,93 $\pm$ 3,26	83,07 $\pm$ 5,03	82,42 $\pm$ 5,49	91,57 $\pm$ 3,55	91,47 $\pm$ 3,82	82,70 $\pm$ 4,54	81,97 $\pm$ 5,15
Spearman_50	79,01 $\pm$ 3,06	77,20 $\pm$ 4,24	76,91 $\pm$ 5,30	74,61 $\pm$ 7,24	80,85 $\pm$ 1,76	79,27 $\pm$ 1,99	77,06 $\pm$ 4,78	75,38 $\pm$ 5,51
Kendall_50	79,73 $\pm$ 4,00	78,23 $\pm$ 3,98	75,77 $\pm$ 5,74	73,94 $\pm$ 5,86	80,53 $\pm$ 2,27	79,36 $\pm$ 2,35	75,17 $\pm$ 6,36	73,39 $\pm$ 5,89
ANOVA_50	84,25 $\pm$ 4,07	83,08 $\pm$ 4,80	73,63 $\pm$ 3,63	70,52 $\pm$ 5,71	81,59 $\pm$ 1,91	80,14 $\pm$ 2,58	73,90 $\pm$ 3,71	70,75 $\pm$ 5,93
MI_50	69,10 $\pm$ 4,07	67,65 $\pm$ 4,03	65,81 $\pm$ 9,92	63,85 $\pm$ 11,72	71,01 $\pm$ 3,29	71,11 $\pm$ 3,53	70,65 $\pm$ 7,21	70,45 $\pm$ 7,92
RFE_50	87,50 $\pm$ 3,55	86,68 $\pm$ 4,30	80,83 $\pm$ 4,05	80,05 $\pm$ 4,11	82,18 $\pm$ 13,63	79,79 $\pm$ 17,50	79,93 $\pm$ 3,69	79,23 $\pm$ 3,57
Pearson_50	82,87 $\pm$ 5,16	81,47 $\pm$ 6,01	77,96 $\pm$ 5,32	76,12 $\pm$ 6,04	86,49 $\pm$ 0,92	85,89 $\pm$ 1,16	78,17 $\pm$ 6,30	76,80 $\pm$ 6,49

Cuadro 2: KNN_10

Filtrado	Sin filtrado		PCA_10		LDA		ICA_10	
	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD
None	88,97 $\pm$ 1,40	88,80 $\pm$ 1,36	83,39 $\pm$ 2,25	83,06 $\pm$ 2,27	95,40 $\pm$ 2,05	95,36 $\pm$ 2,10	84,15 $\pm$ 2,22	83,95 $\pm$ 2,27
Spearman_50	80,49 $\pm$ 2,98	79,26 $\pm$ 3,04	76,42 $\pm$ 2,97	74,80 $\pm$ 3,46	84,02 $\pm$ 3,33	83,05 $\pm$ 3,52	75,28 $\pm$ 3,06	73,73 $\pm$ 3,50
Kendall_50	77,41 $\pm$ 2,93	76,07 $\pm$ 2,91	74,67 $\pm$ 3,48	73,07 $\pm$ 3,46	84,19 $\pm$ 2,76	83,12 $\pm$ 3,10	73,72 $\pm$ 3,44	72,14 $\pm$ 3,35
ANOVA_50	79,73 $\pm$ 0,71	79,08 $\pm$ 0,89	72,87 $\pm$ 1,61	71,99 $\pm$ 1,95	85,21 $\pm$ 2,46	84,97 $\pm$ 2,34	71,76 $\pm$ 1,47	71,07 $\pm$ 1,93
MI_50	72,93 $\pm$ 6,06	73,73 $\pm$ 5,89	71,30 $\pm$ 5,54	71,91 $\pm$ 5,26	74,78 $\pm$ 5,97	75,72 $\pm$ 5,90	71,29 $\pm$ 5,70	71,98 $\pm$ 5,63
RFE_50	84,73 $\pm$ 2,65	84,30 $\pm$ 2,68	79,61 $\pm$ 3,17	79,07 $\pm$ 2,77	89,09 $\pm$ 2,27	88,72 $\pm$ 2,48	77,95 $\pm$ 2,88	77,37 $\pm$ 2,44
Pearson_50	82,82 $\pm$ 2,48	81,84 $\pm$ 2,61	77,43 $\pm$ 3,87	75,74 $\pm$ 4,55	88,33 $\pm$ 1,58	87,76 $\pm$ 1,72	76,20 $\pm$ 2,86	74,50 $\pm$ 3,13

Cuadro 3: KNN_20

Filtrado	Sin filtrado		PCA_10		LDA		ICA_10	
	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD
None	89,00 $\pm$ 2,03	88,84 $\pm$ 2,00	84,17 $\pm$ 2,01	83,82 $\pm$ 2,03	95,43 $\pm$ 2,03	95,39 $\pm$ 2,07	84,86 $\pm$ 1,82	84,66 $\pm$ 1,80
Spearman_50	80,79 $\pm$ 3,39	79,38 $\pm$ 3,56	76,18 $\pm$ 3,43	74,36 $\pm$ 4,09	84,80 $\pm$ 3,12	83,87 $\pm$ 3,27	75,61 $\pm$ 3,69	73,95 $\pm$ 4,25
Kendall_50	77,69 $\pm$ 3,41	76,29 $\pm$ 3,49	75,06 $\pm$ 3,49	73,38 $\pm$ 3,44	84,86 $\pm$ 2,77	83,79 $\pm$ 3,02	74,17 $\pm$ 3,96	72,53 $\pm$ 4,04
ANOVA_50	80,45 $\pm$ 1,26	79,72 $\pm$ 1,31	73,13 $\pm$ 1,48	72,25 $\pm$ 1,81	85,43 $\pm$ 2,76	85,17 $\pm$ 2,68	72,79 $\pm$ 1,41	72,06 $\pm$ 1,97
ML_50	73,14 $\pm$ 6,09	73,92 $\pm$ 6,08	72,38 $\pm$ 5,58	72,96 $\pm$ 5,48	75,22 $\pm$ 5,65	76,04 $\pm$ 5,73	72,06 $\pm$ 5,92	72,68 $\pm$ 5,95
RFE_50	85,02 $\pm$ 2,04	84,53 $\pm$ 2,02	80,47 $\pm$ 3,15	79,88 $\pm$ 2,75	89,47 $\pm$ 2,19	89,12 $\pm$ 2,43	79,26 $\pm$ 3,05	78,70 $\pm$ 2,55
Pearson_50	82,71 $\pm$ 3,00	81,64 $\pm$ 3,24	77,63 $\pm$ 3,62	75,90 $\pm$ 4,08	88,52 $\pm$ 1,65	87,93 $\pm$ 1,86	76,50 $\pm$ 3,73	74,73 $\pm$ 4,06

Cuadro 4: MLP_50

Filtrado	Sin filtrado		PCA_10		LDA		ICA_10	
	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD
None	91,99 $\pm$ 3,21	91,60 $\pm$ 3,42	83,54 $\pm$ 5,06	82,82 $\pm$ 5,53	89,66 $\pm$ 3,92	89,43 $\pm$ 4,43	82,93 $\pm$ 4,22	82,22 $\pm$ 4,68
Spearman_50	80,06 $\pm$ 2,76	78,14 $\pm$ 4,03	77,26 $\pm$ 5,34	74,85 $\pm$ 7,41	81,40 $\pm$ 2,92	80,11 $\pm$ 2,74	78,26 $\pm$ 4,17	76,45 $\pm$ 5,39
Kendall_50	79,71 $\pm$ 3,78	78,32 $\pm$ 3,81	75,87 $\pm$ 6,19	74,20 $\pm$ 6,49	81,44 $\pm$ 1,93	80,28 $\pm$ 2,04	76,41 $\pm$ 6,24	74,81 $\pm$ 5,99
ANOVA_50	83,88 $\pm$ 4,21	82,70 $\pm$ 4,92	73,89 $\pm$ 3,49	70,95 $\pm$ 5,51	80,74 $\pm$ 1,22	79,28 $\pm$ 1,58	73,84 $\pm$ 3,70	70,76 $\pm$ 5,92
ML_50	68,07 $\pm$ 4,51	66,66 $\pm$ 4,71	65,15 $\pm$ 9,96	63,04 $\pm$ 11,79	71,34 $\pm$ 3,48	71,48 $\pm$ 3,70	71,04 $\pm$ 6,67	70,92 $\pm$ 7,41
RFE_50	87,74 $\pm$ 3,76	87,02 $\pm$ 4,49	81,16 $\pm$ 4,57	80,44 $\pm$ 4,58	83,27 $\pm$ 11,83	81,40 $\pm$ 14,67	80,39 $\pm$ 4,24	79,71 $\pm$ 4,22
Pearson_50	83,04 $\pm$ 5,32	81,74 $\pm$ 6,12	77,83 $\pm$ 4,51	75,97 $\pm$ 5,11	85,90 $\pm$ 2,57	85,14 $\pm$ 2,83	79,15 $\pm$ 4,91	77,79 $\pm$ 5,25

Cuadro 5: SVM_0.1

Filtrado	Sin filtrado		PCA_10		LDA		ICA_10	
	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD
None	89,50 $\pm$ 2,19	89,39 $\pm$ 2,20	85,24 $\pm$ 2,19	84,93 $\pm$ 2,09	94,42 $\pm$ 1,89	94,29 $\pm$ 2,02	85,03 $\pm$ 2,33	84,73 $\pm$ 2,41
Spearman_50	80,68 $\pm$ 3,83	79,37 $\pm$ 3,91	77,55 $\pm$ 4,37	75,65 $\pm$ 4,87	81,87 $\pm$ 2,83	80,78 $\pm$ 2,99	77,52 $\pm$ 4,22	75,85 $\pm$ 4,89
Kendall_50	80,81 $\pm$ 4,63	79,60 $\pm$ 4,80	77,00 $\pm$ 5,55	74,47 $\pm$ 7,14	82,97 $\pm$ 3,41	81,90 $\pm$ 3,56	78,20 $\pm$ 4,74	76,44 $\pm$ 5,68
ANOVA_50	83,52 $\pm$ 4,14	82,85 $\pm$ 4,47	74,07 $\pm$ 2,66	72,93 $\pm$ 3,28	85,22 $\pm$ 2,56	84,85 $\pm$ 2,63	74,77 $\pm$ 2,40	73,68 $\pm$ 3,24
ML_50	69,76 $\pm$ 7,97	69,81 $\pm$ 8,50	67,40 $\pm$ 8,52	67,60 $\pm$ 9,15	73,15 $\pm$ 5,95	74,21 $\pm$ 5,85	69,53 $\pm$ 7,52	69,79 $\pm$ 7,63
RFE_50	88,14 $\pm$ 2,04	87,82 $\pm$ 1,97	82,57 $\pm$ 3,77	82,20 $\pm$ 3,40	89,16 $\pm$ 2,72	88,79 $\pm$ 2,96	82,09 $\pm$ 3,44	81,63 $\pm$ 3,11
Pearson_50	84,77 $\pm$ 4,65	83,99 $\pm$ 4,85	77,78 $\pm$ 4,48	75,77 $\pm$ 4,33	87,70 $\pm$ 0,84	87,03 $\pm$ 0,89	79,75 $\pm$ 4,96	78,09 $\pm$ 5,67

Cuadro 6: MLP_100-50

Filtrado	Sin filtrado		PCA_10		LDA		ICA_10	
	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD
None	90,03 $\pm$ 2,87	89,44 $\pm$ 3,28	82,66 $\pm$ 5,22	81,76 $\pm$ 6,01	92,07 $\pm$ 5,03	91,92 $\pm$ 5,27	82,77 $\pm$ 4,52	81,93 $\pm$ 5,26
Spearman_50	77,58 $\pm$ 4,31	75,62 $\pm$ 4,74	74,84 $\pm$ 4,94	72,82 $\pm$ 6,49	80,39 $\pm$ 1,81	78,31 $\pm$ 3,68	74,71 $\pm$ 5,26	72,93 $\pm$ 6,41
Kendall_50	78,45 $\pm$ 5,82	77,08 $\pm$ 5,56	72,97 $\pm$ 6,73	70,96 $\pm$ 6,83	78,12 $\pm$ 4,01	76,74 $\pm$ 3,71	73,60 $\pm$ 8,21	71,72 $\pm$ 8,49
ANOVA_50	82,66 $\pm$ 4,98	81,25 $\pm$ 5,71	72,84 $\pm$ 3,02	68,92 $\pm$ 5,45	83,17 $\pm$ 1,85	82,17 $\pm$ 2,67	73,29 $\pm$ 3,03	70,38 $\pm$ 5,24
ML_50	69,10 $\pm$ 4,81	67,49 $\pm$ 4,85	67,89 $\pm$ 9,69	66,46 $\pm$ 11,08	71,53 $\pm$ 3,71	71,65 $\pm$ 3,78	70,91 $\pm$ 7,95	70,70 $\pm$ 8,89
RFE_50	87,24 $\pm$ 3,28	86,46 $\pm$ 3,95	78,98 $\pm$ 3,96	78,32 $\pm$ 4,21	74,20 $\pm$ 30,95	70,91 $\pm$ 36,72	78,64 $\pm$ 4,16	77,82 $\pm$ 4,43
Pearson_50	80,64 $\pm$ 4,37	79,10 $\pm$ 4,98	76,38 $\pm$ 4,39	74,56 $\pm$ 4,78	84,87 $\pm$ 1,92	84,22 $\pm$ 2,11	76,91 $\pm$ 6,14	75,52 $\pm$ 6,42

Cuadro 7: KNN_1

Filtrado	Sin filtrado		PCA_10		LDA		ICA_10	
	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD
None	86,64 $\pm$ 1,18	86,41 $\pm$ 1,14	80,61 $\pm$ 1,54	80,28 $\pm$ 1,61	94,76 $\pm$ 1,78	94,75 $\pm$ 1,81	80,97 $\pm$ 1,29	80,74 $\pm$ 1,43
Spearman_50	78,58 $\pm$ 2,83	77,36 $\pm$ 2,95	74,05 $\pm$ 2,63	72,35 $\pm$ 3,42	81,39 $\pm$ 2,42	80,21 $\pm$ 2,69	72,36 $\pm$ 2,19	70,69 $\pm$ 2,65
Kendall_50	75,12 $\pm$ 3,20	73,69 $\pm$ 3,19	72,96 $\pm$ 2,75	71,26 $\pm$ 2,90	81,33 $\pm$ 2,72	80,13 $\pm$ 3,12	71,63 $\pm$ 3,18	69,85 $\pm$ 3,32
ANOVA_50	75,95 $\pm$ 1,70	75,28 $\pm$ 1,75	69,24 $\pm$ 0,97	68,30 $\pm$ 1,24	82,16 $\pm$ 2,83	81,78 $\pm$ 2,86	68,66 $\pm$ 1,42	68,04 $\pm$ 1,58
ML_50	69,99 $\pm$ 6,00	70,86 $\pm$ 5,71	67,62 $\pm$ 6,05	68,33 $\pm$ 5,62	72,03 $\pm$ 6,90	73,15 $\pm$ 6,48	67,30 $\pm$ 6,04	68,08 $\pm$ 5,67
RFE_50	80,27 $\pm$ 2,93	79,85 $\pm$ 2,84	74,85 $\pm$ 4,72	74,34 $\pm$ 4,34	86,03 $\pm$ 3,04	85,60 $\pm$ 3,35	73,78 $\pm$ 3,91	73,18 $\pm$ 3,49
Pearson_50	80,35 $\pm$ 2,06	79,32 $\pm$ 1,96	75,29 $\pm$ 2,67	73,58 $\pm$ 3,13	85,62 $\pm$ 1,95	84,89 $\pm$ 2,29	73,94 $\pm$ 2,32	72,20 $\pm$ 2,93

Cuadro 8: SVM_0.5

Filtrado	Sin filtrado		PCA_10		LDA		ICA_10	
	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD
None	90,40 $\pm$ 2,04	90,32 $\pm$ 2,05	85,81 $\pm$ 2,23	85,55 $\pm$ 2,20	95,02 $\pm$ 1,84	94,94 $\pm$ 1,95	85,61 $\pm$ 2,41	85,34 $\pm$ 2,52
Spearman_50	81,92 $\pm$ 3,63	80,73 $\pm$ 3,71	78,23 $\pm$ 4,22	76,46 $\pm$ 4,84	83,20 $\pm$ 2,64	82,16 $\pm$ 2,91	78,15 $\pm$ 4,05	76,61 $\pm$ 4,73
Kendall_50	82,15 $\pm$ 4,19	80,97 $\pm$ 4,31	77,92 $\pm$ 5,11	75,48 $\pm$ 6,49	84,09 $\pm$ 3,02	83,05 $\pm$ 3,18	79,11 $\pm$ 4,38	77,45 $\pm$ 5,27
ANOVA_50	84,41 $\pm$ 3,86	83,82 $\pm$ 4,03	75,22 $\pm$ 2,48	74,06 $\pm$ 3,02	86,27 $\pm$ 2,31	85,90 $\pm$ 2,44	75,86 $\pm$ 2,33	74,81 $\pm$ 3,07
ML_50	71,02 $\pm$ 7,31	71,14 $\pm$ 7,86	68,92 $\pm$ 8,03	69,12 $\pm$ 8,57	74,89 $\pm$ 5,44	75,94 $\pm$ 5,36	71,04 $\pm$ 7,09	71,26 $\pm$ 7,21
RFE_50	89,36 $\pm$ 1,96	89,05 $\pm$ 1,93	83,94 $\pm$ 3,55	83,60 $\pm$ 3,27	90,12 $\pm$ 2,41	89,79 $\pm$ 2,66	83,51 $\pm$ 3,21	83,07 $\pm$ 2,98
Pearson_50	85,91 $\pm$ 4,21	85,21 $\pm$ 4,46	78,63 $\pm$ 4,26	76,77 $\pm$ 4,17	88,74 $\pm$ 0,92	88,12 $\pm$ 0,98	80,66 $\pm$ 4,71	79,09 $\pm$ 5,38

Cuadro 9: SVM_1

Filtrado	Sin filtrado		PCA_10		LDA		ICA_10	
	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD	ACC $\pm$ STD	F1 $\pm$ STD
None	90,91 $\pm$ 1,96	90,84 $\pm$ 1,97	86,17 $\pm$ 2,18	85,93 $\pm$ 2,14	95,35 $\pm$ 1,72	95,29 $\pm$ 1,83	85,98 $\pm$ 2,35	85,74 $\pm$ 2,48
Spearman_50	82,64 $\pm$ 3,49	81,53 $\pm$ 3,56	78,96 $\pm$ 4,09	77,27 $\pm$ 4,71	84,08 $\pm$ 2,52	83,07 $\pm$ 2,77	78,87 $\pm$ 3,94	77,41 $\pm$ 4,60
Kendall_50	82,91 $\pm$ 4,01	81,76 $\pm$ 4,13	78,47 $\pm$ 4,93	76,12 $\pm$ 6,22	84,77 $\pm$ 2,91	83,77 $\pm$ 3,06	79,74 $\pm$ 4,22	78,15 $\pm$ 5,09
ANOVA_50	85,02 $\pm$ 3,71	84,47 $\pm$ 3,89	76,06 $\pm$ 2,31	74,96 $\pm$ 2,86	86,98 $\pm$ 2,19	86,63 $\pm$ 2,33	76,63 $\pm$ 2,22	75,61 $\pm$ 2,94
ML_50	71,74 $\pm$ 7,12	71,92 $\pm$ 7,63	69,63 $\pm$ 7,81	69,89 $\pm$ 8,32	75,63 $\pm$ 5,22	76,61 $\pm$ 5,18	71,82 $\pm$ 6,91	72,04 $\pm$ 7,05
RFE_50	89,88 $\pm$ 1,89	89,60 $\pm$ 1,86	84,53 $\pm$ 3,42	84,21 $\pm$ 3,18	90,61 $\pm$ 2,28	90,30 $\pm$ 2,53	84,08 $\pm$ 3,11	83,67 $\pm$ 2,87
Pearson_50	86,54 $\pm$ 4,02	85,88 $\pm$ 4,29	79,21 $\pm$ 4,11	77,40 $\pm$ 4,03	89,21 $\pm$ 0,88	88,63 $\pm$ 0,94	81,18 $\pm$ 4,53	79,66 $\pm$ 5,21

Una vez tuvimos los resultados los organizamos según el modelo y su accuracy junto a su F1-Score. Los siguientes resultados (Tablas 10, 11, 12) son la visualización organizada de las anteriores para el Top 5 resultados por parámetro, donde observamos:

- **Combinación: Sin filtrado + LDA.** En las tres familias de modelos (SVM, KNN y MLP), las mejores combinaciones corresponden casi siempre al uso de todas las variables (Sin filtrado) junto con una reducción mediante LDA. Estas configuraciones alcanzan los valores más altos de ACC y F1.

Rank	Filtrado	Reducción	ACC (%)	F1 (%)
SVM_0.5				
1	None	LDA	95,47 $\pm$ 1,86	95,39 $\pm$ 1,93
2	None	None	92,98 $\pm$ 2,54	92,93 $\pm$ 2,50
3	RFE_50	None	90,76 $\pm$ 1,87	90,49 $\pm$ 1,90
4	RFE_50	LDA	89,55 $\pm$ 2,62	89,21 $\pm$ 2,89
5	Pearson_50	LDA	89,10 $\pm$ 1,66	88,56 $\pm$ 1,76
SVM_1				
1	None	LDA	95,39 $\pm$ 1,88	95,32 $\pm$ 1,94
2	None	None	93,87 $\pm$ 2,25	93,84 $\pm$ 2,23
3	RFE_50	None	91,30 $\pm$ 1,79	91,05 $\pm$ 1,83
4	RFE_50	LDA	89,59 $\pm$ 2,63	89,25 $\pm$ 2,91
5	Pearson_50	None	89,34 $\pm$ 3,34	88,84 $\pm$ 3,48
SVM_0.1				
1	None	LDA	94,42 $\pm$ 1,89	94,29 $\pm$ 2,02
2	None	None	89,50 $\pm$ 2,19	89,39 $\pm$ 2,20
3	RFE_50	LDA	89,16 $\pm$ 2,72	88,79 $\pm$ 2,96
4	RFE_50	None	88,14 $\pm$ 2,04	87,82 $\pm$ 1,97
5	Pearson_50	LDA	87,70 $\pm$ 0,84	87,03 $\pm$ 0,89

Cuadro 10: Top-5 combinaciones para modelos SVM (SVM_0.5, SVM_1 y SVM_0.1).

Rank	Filtrado	Reducción	ACC (%)	F1 (%)
KNN_20				
1	None	LDA	95,43 $\pm$ 2,03	95,39 $\pm$ 2,07
2	RFE_50	LDA	89,47 $\pm$ 2,19	89,12 $\pm$ 2,43
3	None	None	89,00 $\pm$ 2,03	88,84 $\pm$ 2,00
4	Pearson_50	LDA	88,52 $\pm$ 1,65	87,93 $\pm$ 1,86
5	ANOVA_50	LDA	85,43 $\pm$ 2,76	85,17 $\pm$ 2,68
KNN_10				
1	None	LDA	95,40 $\pm$ 2,05	95,36 $\pm$ 2,10
2	RFE_50	LDA	89,09 $\pm$ 2,27	88,72 $\pm$ 2,48
3	None	None	88,97 $\pm$ 1,40	88,80 $\pm$ 1,36
4	Pearson_50	LDA	88,33 $\pm$ 1,58	87,76 $\pm$ 1,72
5	ANOVA_50	LDA	85,21 $\pm$ 2,46	84,97 $\pm$ 2,34
KNN_1				
1	None	LDA	94,76 $\pm$ 1,78	94,75 $\pm$ 1,81
2	None	None	86,64 $\pm$ 1,18	86,41 $\pm$ 1,14
3	RFE_50	LDA	86,03 $\pm$ 3,04	85,60 $\pm$ 3,35
4	Pearson_50	LDA	85,62 $\pm$ 1,95	84,89 $\pm$ 2,29
5	ANOVA_50	LDA	82,16 $\pm$ 2,83	81,78 $\pm$ 2,86

Cuadro 11: Top-5 combinaciones para modelos KNN (KNN_20, KNN_10 y KNN_1).

Rank	Filtrado	Reducción	ACC (%)	F1 (%)
MLP_100-50				
1	None	LDA	92,07 $\pm$ 5,03	91,92 $\pm$ 5,27
2	None	None	90,03 $\pm$ 2,87	89,44 $\pm$ 3,28
3	RFE_50	None	87,24 $\pm$ 3,28	86,46 $\pm$ 3,95
4	Pearson_50	LDA	84,87 $\pm$ 1,92	84,22 $\pm$ 2,11
5	ANOVA_50	LDA	83,17 $\pm$ 1,85	82,17 $\pm$ 2,67
MLP_50				
1	None	None	91,99 $\pm$ 3,21	91,60 $\pm$ 3,42
2	None	LDA	89,66 $\pm$ 3,92	89,43 $\pm$ 4,43
3	RFE_50	None	87,74 $\pm$ 3,76	87,02 $\pm$ 4,49
4	Pearson_50	LDA	85,90 $\pm$ 2,57	85,14 $\pm$ 2,83
5	ANOVA_50	None	83,88 $\pm$ 4,21	82,70 $\pm$ 4,92
MLP_100				
1	None	LDA	91,57 $\pm$ 3,55	91,47 $\pm$ 3,82
2	None	None	90,55 $\pm$ 3,03	89,93 $\pm$ 3,26
3	RFE_50	None	87,50 $\pm$ 3,55	86,68 $\pm$ 4,30
4	Pearson_50	LDA	86,49 $\pm$ 0,92	85,89 $\pm$ 1,16
5	ANOVA_50	None	84,25 $\pm$ 4,07	83,08 $\pm$ 4,80

Cuadro 12: Top-5 combinaciones para modelos MLP (MLP_100-50, MLP_50 y MLP_100).

En la Tabla 13 se observamos:

Mejores modelos

- Para **SVM**, la mejor configuración es SVM_0.5 con Sin filtrado y LDA, alcanzando una (ACC = 95.47 %) y (F1 = 95.39 %).
- Para **KNN**, los tres valores de K (1, 10 y 20) obtienen resultados muy similares cuando se combinan con Sin Filtrado y LDA, con F1 por encima del 94.7 %. Aunque el mejor es KNN_20 + LDA, con (F1 = 95.39 %).
- Para **MLP**, la mejor configuración es MLP_100-50 con Sin filtrado y LDA, seguida de cerca por MLP_50 sin reducción.

Selección final de modelos base. A la vista de estos resultados, los modelos que se seleccionan como representantes de cada familia para la fase de evaluación final y para su uso en los compuestos son:

- **SVM:** SVM_0.5 con sin filtrado.
- **KNN:** KNN_20 con sin filtrado y LDA.
- **MLP:** MLP_100-50 con sin filtrado y LDA.

Estos modelos ofrecen los mejores resultados (ACC y F1) y estabilidad en las desviaciones dentro de cada tipo de clasificador.

Model	Rank	Parameters	Filtrado	Reducción	ACC (%)	F1 (%)
SVM						
SVM	1	SVM_0.5	None	LDA	95.47±1.86	95.39±1.93
SVM	2	SVM_1	None	None	95.39±1.88	95.32±1.94
SVM	3	SVM_0.1	None	LDA	94.42±1.89	94.29±2.02
SVM	4	SVM_1	None	None	93.87±2.25	93.84±2.23
SVM	5	SVM_0.5	None	None	92.98±2.54	92.93±2.50
KNN						
KNN	1	KNN_20	None	LDA	95.43±2.03	95.39±2.07
KNN	2	KNN_10	None	LDA	95.40±2.05	95.36±2.10
KNN	3	KNN_1	None	LDA	94.76±1.78	94.75±1.81
KNN	4	KNN_20	RFE_50	LDA	89.47±2.19	89.12±2.43
KNN	5	KNN_10	RFE_50	LDA	89.09±2.27	88.72±2.48
MLP						
MLP	1	MLP_100-50	None	LDA	92.07±5.03	91.92±5.27
MLP	2	MLP_50	None	None	91.99±3.21	91.60±3.42
MLP	3	MLP_100	None	LDA	91.57±3.55	91.47±3.82
MLP	4	MLP_100	None	None	90.55±3.03	89.93±3.26
MLP	5	MLP_100-50	None	None	90.03±2.87	89.44±3.28

Cuadro 13: Top 5 combinaciones por modelo SVM, KNN y MLP, ordenadas por F1 y ACC.

5. Resultados modelos ensemble

Modelo (PCA 95 %)	ACC (%)	F1 (%)
EvoTree50	86.79 ± 2.0	86.39 ± 2.0
Bagging50	88.22 ± 1.5	88.04 ± 1.4
EvoTree100	87.86 ± 1.69	87.49 ± 1.71
Bagging10	88.30 ± 1.49	88.11 ± 1.42

Cuadro 14: Rendimiento de modelos ensemble con reducción PCA reteniendo el 95 % de la varianza (validación cruzada 5-fold).

Según los resultados de la Tabla 14, podemos observar lo siguiente en los modelos de *ensemble*, con una reducción PCA al 95 %:

- **Bagging:** Los modelos de *Bagging* (utilizando KNN como clasificador base) presentan los mejores resultados de este bloque, con una exactitud aproximada del 88.30 %. Es destacable que el aumento en el número de estimadores (de 10 a 50) no produce una mejora significativa, lo que

sugiere que el modelo alcanza su capacidad máxima de generalización con rapidez

- **EvoTree:** Los modelos muestran un rendimiento ligeramente inferior al *Bagging*. No obstante, se observa una tendencia positiva al aumentar el número de estimadores de 50 a 100 (incremento del 1.07 % en ACC), lo que indica que una mayor complejidad estructural permite capturar mejor los patrones de actividad tras el PCA.
- **AdaBoost:** A diferencia de los modelos anteriores, el clasificador AdaBoost se entrenó una única vez sobre el conjunto completo de entrenamiento. Debido a que se fijó el número de estimadores ($n = 5$), no se consideró necesaria la comparativa mediante la validación cruzada para este modelo en particular. Sin embargo, sí que fue comparado con el resto de ensembles (Tabla 16).

6. Resultados finales por bloque

6.1. Modelos básicos

Tras la elección de los mejores parámetros se entrenaron con todo el conjunto.

En la Tabla 15 se muestran los resultados de los tres modelos base seleccionados (KNN con $k = 20$, MLP con arquitectura 100–50 y SVM con $C = 0,5$).

- **SVM ($C = 0,5$)** es el modelo con mejor rendimiento global, alcanzando una **exactitud del 94.50 %** y un **F1 del 94.24 %**, con valores de precisión y *recall* muy equilibrados (94.40 % y 94.30 %). Esto indica que el clasificador comete pocos errores tanto con falsos positivos como con falsos negativos.
- **KNN ($k = 20$)** obtiene resultados también competitivos (92.22 % de *accuracy* y 92.21 % de F1), ligeramente inferiores a SVM pero todavía dentro de un rango alto de rendimiento. Se trata de un modelo sencillo que sirve como buena referencia base.
- **MLP (100–50)** presenta el peor comportamiento de los tres (88.61 % de *accuracy* y 87.64 % de F1), lo que sugiere que, con esta arquitectura y configuración de hiperparámetros, la red neuronal no se ajusta tan bien al problema como los modelos de margen máximo o vecinos más próximos.

Modelo	ACC (%)	REC (%)	F1 (%)	PREC (%)
KNN_20	92.22	92.30	92.21	92.56
MLP_100-50	92.6	92.34	92.23	92.75
SVM_0.5	94.50	94.30	94.24	94.40

Cuadro 15: Rendimiento en test de los mejores modelos básicos seleccionados.

6.2. Modelos ensemble

Modelo	ACC (%)	REC (%)	F1 (%)	PREC (%)
EvoTree50	91.75	91.50	91.51	91.97
AdaBoost	34.63	36.52	25.07	29.85
Bagging10	91.18	91.17	91.07	91.42

Cuadro 16: Rendimiento en test de los modelos ensemble seleccionados.

Los resultados de EvoTree y Bagging son aceptables. Por la contra, AdaBoost da los peores resultados de entre todos los modelos entrenados. Esto se debe a que, como veremos en el apartado de visualización, hay bastante ruido en las clases, lo cual es uno de los puntos débiles de este tipo de modelos.

6.3. Modelos compuestos

Se intentó incluir CatBoosting en estos experimentos pero tuvimos problemas a la hora de ajustar las versiones de las librerías para que funcionase junto a los otros modelos, por lo que nos vimos obligados a descartarlo.

Modelo	ACC (%)	REC (%)	F1 (%)	PREC (%)
RandomForest	97.15	97.18	97.14	97.23
HardVoting	96.02	96.06	96.05	96.28
StackingEnsemble	94.69	94.32	94.11	94.70
XGBoost	96.96	97.00	96.96	97.08
LightGBM	97.06	97.03	96.99	97.10

Cuadro 17: Rendimiento en test de modelos los modelos compuestos.

Todos los modelos dan resultados óptimos, siendo el único que se queda un poco por detrás el StackingEnsemble. Estos modelos poseen una gran capacidad de abstracción y consiguen adaptarse muy bien a datos multidimensionales, por lo que era esperable conseguir este nivel de precisión.

A falta de un test estadístico, no tenemos suficiente información como para saber si RandomForest o LightGBM es mejor ya que ambos tienen resultados muy parejos. Sin embargo, el tiempo de entrenamiento de LightGBM

fue mucho menor que el de RandomForest y el tiempo de predicción debería ser menor también, por lo que en una aplicación real sería mejor implementar LightGBM para poder hacer mejor fine-tuning, tener menor tiempo de respuesta, etc.

7. Gráficas por reducción

En las siguientes imágenes podemos observar como se puede apreciar una agrupación de aquellas actividades que pueden resultar ambiguas para diferenciar. Caminar por escaleras y caminar mantienen agrupaciones parecidas en diferentes tipos de reducciones, por otro lado, en las estáticas ocurre lo mismo. Estar sentado, de pie o tumbado también se agrupan entre ellas.

8. Visualización y análisis de reducciones

En las Figuras 5 a 9 presentamos el conjunto después de aplicar diferentes técnicas de reducción de dimensionalidad. Las cuales nos permiten extraer las siguientes conclusiones:

- **Separación:** Todas las técnicas logran una separación entre las actividades: Laying, Sitting, Standing, contra las dinámicas Walking, Walking_Upstairs, Walking_Downstairs.
- **Eficacia de LDA:** LDA (Figura 7) proporciona una separación clara, agrupando las clases en regiones compactas. Lo que resulta coherente con el buen rendimiento de LDA a lo largo de la experimentación con los modelos básicos cuando se aplica esta reducción.
- **t-SNE:** La proyección **t-SNE** (Figura 9) muestra que las actividades no son grupos uniformes, sino que presentan subgrupos.
- **Confusión entre Sitting y Standing:** En proyecciones como **Iso-map** o **PCA**, se observa un solapamiento entre las clases Sitting y Standing. Esta falta de separación explica que los modelos tiendan a confundir estas dos actividades.



Figura 4: Leyenda para la visualización




Figura 5: PCA




Figura 6: ICA




Figura 7: LDA




Figura 8: Isomap




Figura 9: t-SNE




Figura 10: LLE

9. Significación de variables

A partir de las figuras de importancia de variables obtenidas con *Random Forest* y *XGBoost*, se ha realizado un análisis de la relevancia de las características para la tarea de reconocimiento de actividades.

- Random Forest (500 árboles, profundidad máxima 10).




Figura 11: Random Forest

- XGBoost (por defecto).




Figura 12: XGBoost

En ambos casos se utilizó únicamente el conjunto de entrenamiento. Posteriormente, se representaron las 20 variables más relevantes de cada modelo.

9.1. Importancia según Random Forest

La gráfica de Random Forest 11 muestra que las variables más influyentes son:

- tGravityAcc-min()-X
- angle(X, gravityMean)
- tGravityAcc-mean()-X / tGravityAcc-mean()-Y
- tBodyAccJerk-std()-X
- tGravityAcc-energy()-X

En general, las características más importantes se concentran en componentes debidos a la aceleración de la gravedad.

Esto nos sugiere que el modelo Random Forest se apoya fuertemente en la orientación del dispositivo respecto a la gravedad y en la variabilidad del movimiento para discriminar entre actividades estáticas (SITTING, STANDING, LAYING) y dinámicas (WALKING, WALKING UPSTAIRS, WALKING DOWNSTAIRS).

9.2. Importancia según XGBoost

En el caso de XGBoost 12, las variables mejor posicionadas son:

- `fBodyAccJerk-std()-Y`
- `fBodyAcc-bandsEnergy()-1,24.1`
- `fBodyAccJerk-mad()-Y`
- `tBodyAcc-energy()-X`
- `tGravityAcc-mean()-X`

Se observa aquí un patrón diferente, en el que XGBoost se centra más en el movimiento, cambios en la aceleración, movimientos dinámicos, etc.

9.3. Conclusión de la significación por variables

En conclusión, ambos modelos coinciden en resaltar la importancia de la orientación respecto a la gravedad (`tGravityAcc-mean()`) pero difieren en variables: Random Forest se centra más en las medidas estáticas, mientras que XGBoost se centra en la parte más dinámica. Estos conjuntos de variables explican el buen desempeño de Random Forest y XGBoost a la hora de clasificar, centrándose en las actividades estáticas o dinámicas para discriminar entre ellas.